TCC / REUNIÃO DE ORIENTAÇÃO

Saúde e clima no estado de São Paulo

Pipeline de dados e dashboard analítico
Internações hospitalares de 2023 a 2025

Guilherme
30 de setembro de 2026

Tema e objetivo do trabalho

Integração de internações hospitalares e condições meteorológicas

Objetivo da solução

Organizar fontes heterogêneas em uma base analítica e disponibilizar sua exploração no Power BI.

Recorte

Estado de São Paulo. Internações com data entre janeiro de 2023 e dezembro de 2025.

Pergunta para a redação

Como integrar esses dados e explorar padrões de internação associados às condições meteorológicas?

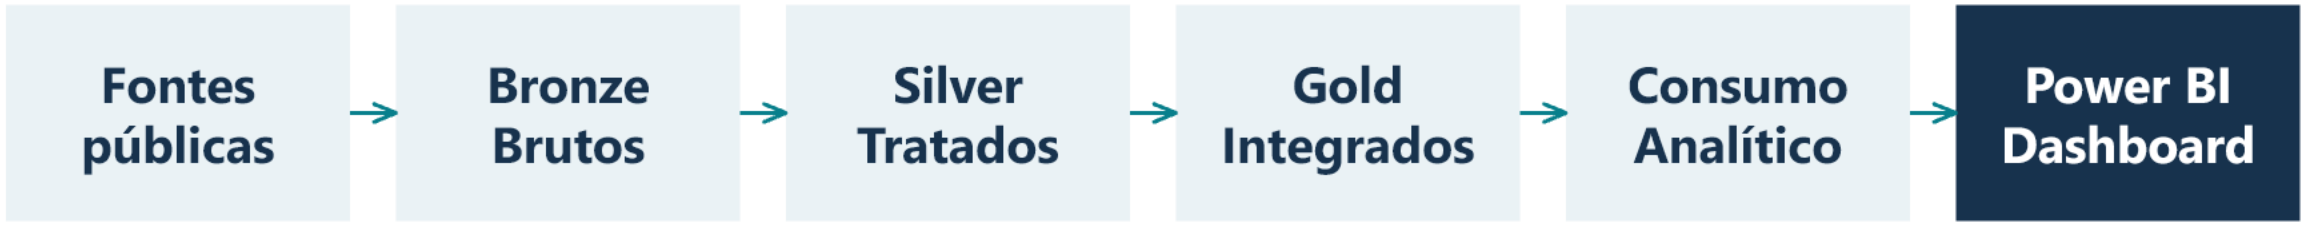
Fontes e dimensão da entrega

Fonte	Conteúdo integrado	Dimensão documentada
SIH / DATASUS	Registros de internações hospitalares	8.409.047 registros na Gold
INMET	Observações meteorológicas	40 estações e 43.840 estação-dias
IBGE	Municípios e informação geográfica	645 municípios de São Paulo
CID-10	Classificação dos diagnósticos	1.658 categorias no consumo

8.236.990 internações no recorte por data de internação (2023–2025)

Arquitetura da solução

Airflow: dependências, execução e acompanhamento do pipeline



Qualidade após cada camada de dados

Python e Apache Spark em Docker
Persistência em arquivos Parquet nas camadas tratadas

A camada de consumo também utiliza dados complementares da Silver aprovada.

Arquitetura tecnológica



Spark executa os jobs no ambiente local. Power BI importa os Parquets da camada de consumo.

Função de cada tecnologia

Tecnologia	Responsabilidade no projeto
Docker Compose	Organiza contêineres, dependências e pastas compartilhadas
Apache Airflow	Coordena tarefas, dependências, tentativas e falhas
Python + Spark / PySpark	Ingestão, transformações, joins, agregações e qualidade
PostgreSQL + Redis	Metadados do Airflow e fila de execução das tarefas
Parquet	Armazena tabelas tratadas e dados para consumo analítico
JupyterLab	Apoia exploração dos dados e testes de desenvolvimento
Power BI + Power Query + DAX	Importa dados, relaciona tabelas e apresenta indicadores

O papel de cada camada

Camada	Responsabilidade	Controle de qualidade
Bronze	Preserva os arquivos recebidos	Chegada, integridade e legibilidade
Silver	Limpa, tipa e padroniza os dados	Tipos, chaves, domínios e períodos
Gold	Integra internação e meteorologia	Joins, cardinalidade e cobertura
Consumo	Agrega fatos e prepara dimensões	Reconciliação dos totais e lags

Falhas críticas interrompem o fluxo. Avisos e métricas informativas ficam registrados.

Integração de saúde e meteorologia



Vínculo espacial

645 municípios associados a 40 estações.
Distância média documentada: 34,29 km.

Vínculo temporal

A data da internação determina o encontro com a observação diária da estação.

A competência do arquivo SIH e a data de internação têm funções diferentes no projeto.

Orquestração e evidências de qualidade

Airflow concluído

Dependências entre camadas, execução dos processamentos e bloqueio em falhas críticas.

Consumo validado

Totais reconciliados com a Gold. Sem duplicidades nas chaves das duas fatos.

33min26s

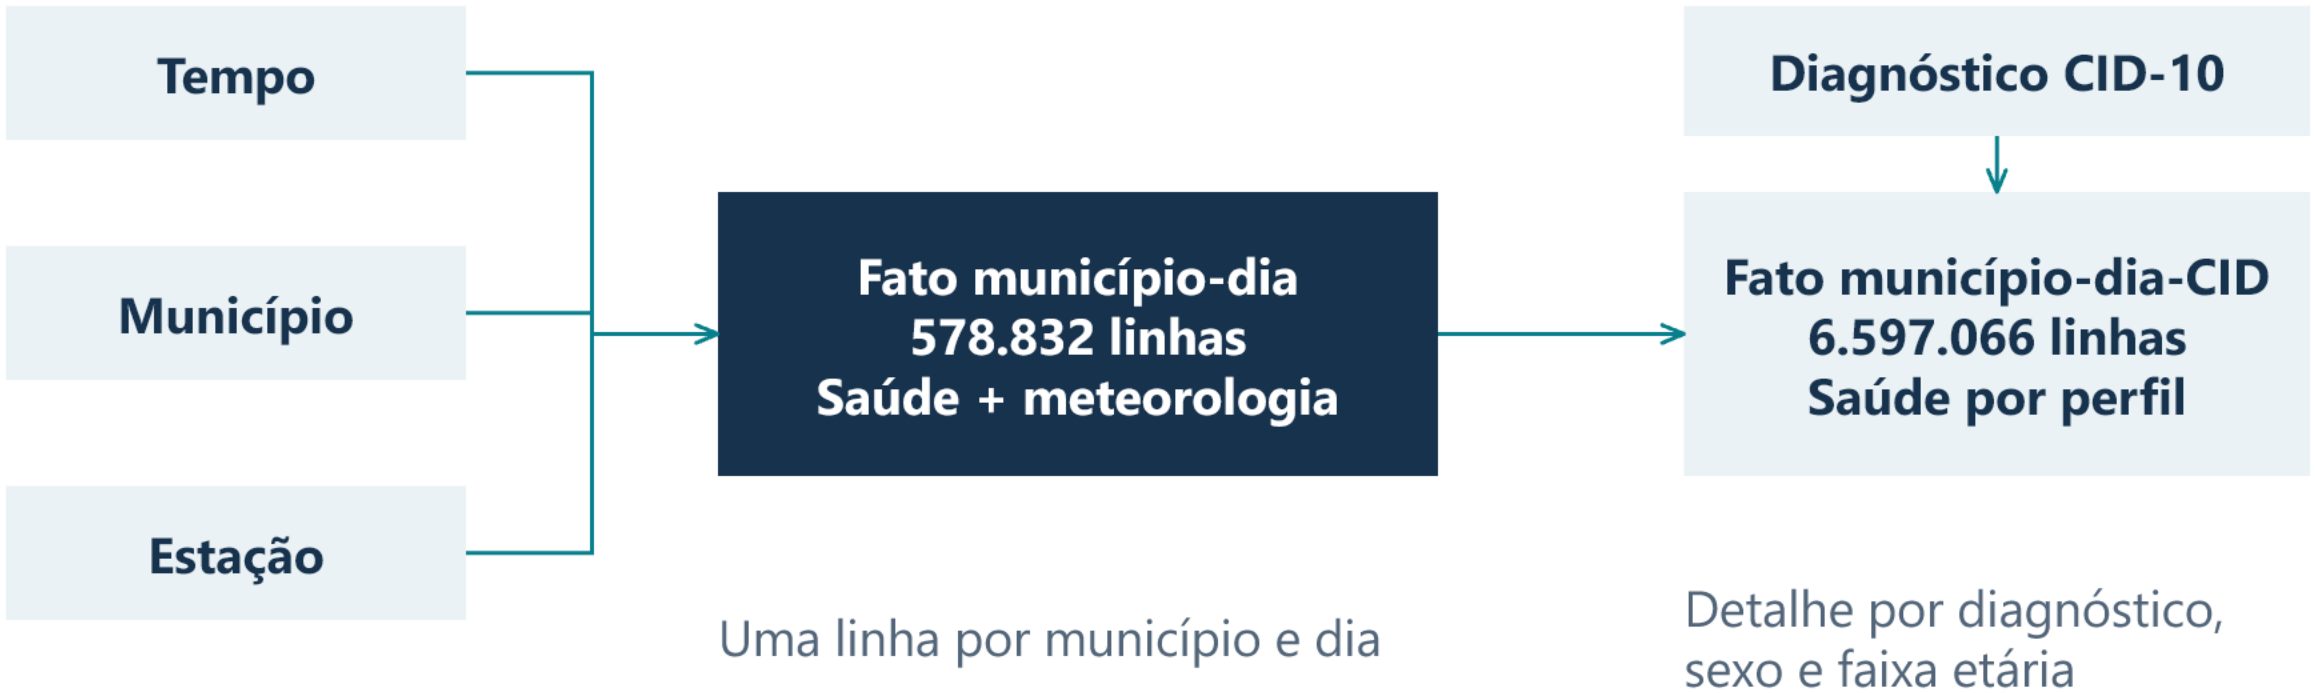
execução documentada até a Gold

8 testes

sintéticos aprovados na camada de consumo

Medições históricas de setembro. O tempo acima antecede a inclusão do consumo na DAG.

Modelo analítico do dashboard



Duas granularidades complementares, com os mesmos totais de saúde reconciliados.

Dashboard concluído: seis páginas

01	**Visão geral**	Volume, desfechos e valores registrados
02	**Meteorologia × internações**	Evolução temporal e faixas de temperatura
03	**CID × temperatura**	Capítulos, grupos e categorias diagnósticas
04	**Defasagem da temperatura**	Mesmo dia e 1, 3 e 7 dias anteriores
05	**Outras variáveis**	Umidade, chuva, radiação, vento e pressão
06	**Análise territorial**	Mapa municipal e comparação entre municípios

01 Visão geral das internações

8.236.990

internações no recorte analítico

422.557 óbitos nas internações
5,13% de óbitos / internações
4,84 dias de permanência média
R$ 14,39 bilhões registrados

Visuais da página

Evolução mensal, municípios com mais internações e distribuição por capítulo CID-10.

Na demonstração

Aplicar ano, mês e município para mostrar como os indicadores respondem ao recorte.

Totais documentados da camada de consumo. Proporções calculadas sobre as internações.

02 Temperatura e internações

Frio < 20 °C

Quente ≥ 25 °C

Média de internações = internações ÷ município-dias observados

Leitura temporal

Comparação mensal entre volume de internações e temperatura média de 2023 a 2025.

Comparação dos recortes

Médias por faixa de temperatura e variação relativa entre condições frias e quentes.

Os limiares são escolhas analíticas do dashboard e devem ser justificados na metodologia.

03 Diagnósticos e temperatura



O que a página mostra

Variação entre dias frios e quentes em diferentes níveis da classificação CID-10.

Na demonstração

Manter o mesmo ano e município e acompanhar a mudança do capítulo até a categoria.

O detalhamento utiliza a fato por CID, sem duplicar a meteorologia a cada diagnóstico.

04 Defasagem da temperatura

Internações do dia observado

Mesmo dia	1 dia antes	3 dias antes	7 dias antes
Temperatura	Temperatura	Temperatura	Temperatura

Comparação das médias frio × calor e da variação relativa em cada defasagem

Ausência de medição permanece nula. A data de internação não se desloca.

05 Outras variáveis meteorológicas

Variável	Exploração disponível
Umidade relativa	Comparação por faixas percentuais
Precipitação	Dias sem chuva e faixas de volume diário
Radiação solar	Faixas de energia diária acumulada
Vento	Faixas de velocidade média diária
Pressão atmosférica	Faixas da amplitude diária

Indicador comum: média de internações por município-dia observado.

06 Análise territorial

A dimensão municipal organiza a leitura espacial

Mapa municipal

Localização dos municípios e variação entre médias de internação em dias frios e quentes.

Ranking e detalhes

Top 10 da variação e informações de médias, diferença absoluta e amostra nos detalhes.

Na demonstração: selecionar um município e explicar o indicador junto com seus denominadores.

Entrega concluída e foco na escrita

Solução implementada

Pipeline de dados, qualidade, orquestração e dashboard concluídos.

Etapa atual

Redação do TCC e organização das evidências da solução e das análises.

Parte do TCC	Material já disponível
Metodologia e arquitetura	Fontes, camadas, critérios de integração e qualidade
Implementação	Pipeline, Airflow, modelo analítico e dashboard
Resultados e discussão	Totais reconciliados, desempenho e seis páginas analíticas

Organização proposta para o TCC

1	**Introdução**	Problema, objetivo, justificativa e recorte
2	**Fundamentação**	Engenharia de dados, qualidade e saúde/clima
3	**Metodologia**	Fontes, integração e regras analíticas
4	**Desenvolvimento**	Arquitetura, orquestração e dashboard
5	**Resultados e discussão**	Evidências técnicas e análises descritivas
6	**Conclusão**	Contribuições, limitações e trabalhos futuros

Alinhamentos para a redação

Solução técnica concluída
Próxima entrega: texto do TCC

Objetivo e título definitivos
Resultados e figuras que entram no texto
Profundidade da discussão sobre saúde e clima
Sequência de capítulos e cronograma de revisão