

Auditoria técnica da camada Bronze

Inventário, riscos e proposta de integração ao Apache Airflow

9 de setembro de 2026

Sumário

1	Objetivo, escopo e conclusão	2
2	Baseline operacional	2
3	Inventário dos scripts e fontes	2
3.1	Endpoints registrados no código	3
4	Estrutura real dos datasets	3
4.1	Inspeção leve dos ZIPs	4
5	Relação Bronze–Silver	4
6	Estado dos DQs Bronze	5
6.1	Falhas e integração com tasks Python	5
7	Idempotência e reprocessamento	5
8	Dependências externas e ambiente	6
9	Proposta de TaskGroups e operators	7
10	Grafo completo proposto	7
11	Estratégia de retries proposta	8
12	Incrementalidade e as 36 competências SIH	9
13	Problemas e ambiguidades encontrados	9
14	Segurança dos dados e implementação futura	10
15	Impacto provável no tempo de execução	10
15.1	Cinco oportunidades simples para investigar	10
16	Próxima etapa recomendada	11
17	Evidências e limitações da auditoria	11

1 Objetivo, escopo e conclusão

Este documento registra a auditoria da camada Bronze do TCC de Engenharia de Dados e a proposta de integração à DAG `tcc_pipeline`. A auditoria foi realizada por leitura do repositório, listagens de arquivos, consulta aos metadados dos ZIPs e imports leves no worker Airflow. Não houve downloads, execução dos DQs completos, conversão de dados ou execução do pipeline.

Durante a auditoria, nenhum arquivo foi modificado. Este Markdown e sua versão PDF foram criados posteriormente, mediante solicitação de documentação. As propostas deste relatório não foram implementadas.

A Bronze já possui funções de aquisição para SIH, INMET e IBGE, além de extração local para CID-10. Os quatro DQs Bronze existem. A integração exige wrappers que respeitem os resultados dos gates, parâmetros temporais explícitos e tratamento cuidadoso dos arquivos existentes.

Os achados centrais são: dependência cruzada da Silver SIH em Bronze IBGE; aquisição externa CID-10 não implementada; downloads que verificam existência, mas não integridade; e custo potencialmente relevante dos DQs SIH e INMET.

2 Baseline operacional

O usuário informou que as 16 tasks atuais de Silver, DQ Silver, Gold e DQ Gold terminaram em SUCCESS em uma execução completa de aproximadamente 45 minutos. Esse é o baseline operacional informado, não uma medição realizada nesta auditoria.

A DAG possui cinco TaskGroups: `inmet`, `ibge`, `cid10`, `sih` e `gold`. O ambiente do projeto utiliza Airflow 3.3.1, Spark/PySpark 3.5.0, Python 3.11, Java 17, Docker e arquitetura Bronze–Silver–Gold.

3 Inventário dos scripts e fontes

Fonte	Script e funções	Entrada	Saída e método
SIH	<code>src/bronze/sih.py</code> ; <code>download_sih</code> e <code>download_sih_periodo</code>	FTP DATASUS	DBC mensal, download <code>urllib</code>
INMET	<code>src/bronze/inmet.py</code> ; <code>download_inmet</code>	HTTPS INMET	ZIP anual, download <code>urllib</code> em blocos
IBGE	<code>src/bronze/ibge.py</code> ; <code>download_malha_sp_2022</code>	HTTPS IBGE	ZIP original SP/2022, download <code>urllib</code> em blocos
CID-10	<code>src/bronze/cid10.py</code> ; <code>processar_cid10</code> e <code>extrair_cid10</code>	CID10CSV.zip local	Extração de quatro CSVs

Os módulos de aquisição SIH, INMET e IBGE definem funções, mas não possuem um bloco de execução que dispare a coleta. Executar apenas o arquivo Python não inicia o download. CID-10 possui bloco **main** que chama a preparação local.

A busca fora de `src/bronze` não identificou outro fluxo implementado de aquisição. O notebook de validação contém referências e erros históricos de importação do PySUS; isso não torna PySUS uma dependência dos coletores atuais.

3.1 Endpoints registrados no código

SIH:

```
ftp://ftp.datasus.gov.br/dissemin/publicos/SIHSUS/  
200801_/Dados/RDSP{AA}-{MM}.dbc
```

INMET:

```
https://portal.inmet.gov.br/uploads/dadoshistoricos/{ANO}.zip
```

IBGE:

```
https://geoftp.ibge.gov.br/organizacao_do_territorio/  
malhas_territoriais/malhas_municipais/municipio_2022/  
UFs/SP/SP_Municipios_2022.zip
```

As quebras acima são apenas para apresentação. Não há autenticação explícita nos coletores. Apesar do nome geoftp, o script IBGE utiliza HTTPS.

Não foi encontrada URL ou implementação de download do ZIP CID-10. Sua aquisição deve ser tratada como provisionamento externo, possivelmente manual, sem afirmar uma origem não comprovada pelo repositório. Fonte, versão e política de atualização precisam ser documentadas antes de automatizar essa etapa.

4 Estrutura real dos datasets

A listagem encontrou 45 arquivos, aproximadamente 978 MB em unidades decimais, sem arquivos com extensão .tmp.

data/bronze/

sih/

```
2023/RDSP2301.dbc ... RDSP2312.dbc  
2024/RDSP2401.dbc ... RDSP2412.dbc  
2025/RDSP2501.dbc ... RDSP2512.dbc
```

inmet/

```
2023/2023.zip  
2024/2024.zip  
2025/2025.zip
```

ibge/

```
2022/SP_Municipios_2022.zip
```

cid10/

```
CID10CSV.zip  
CID-10-CAPITULOS.CSV  
CID-10-GRUPOS.CSV  
CID-10-CATEGORIAS.CSV  
CID-10-SUBCATEGORIAS.CSV
```

Fonte	Arquivos	Bytes	Granularidade e organização
SIH	36	665.115.072	Um DBC RD de SP por competência; registros administrativos de internação/AIH
INMET	3	300.740.085	ZIP nacional por ano; CSVs por estação com observações horárias
IBGE	1	10.464.202	Malha municipal de SP, referência 2022; atributos e geometrias
CID-10	5	1.885.997	ZIP e quatro tabelas hierárquicas de classificação

A Bronze preserva DBC, ZIP e CSV, não Parquet. As conversões pertencem às etapas seguintes. A estrutura temporal e os nomes atuais são consumidos diretamente pela Silver.

4.1 Inspeção leve dos ZIPs

Foram consultados somente os diretórios centrais dos arquivos, sem extração ou teste integral de CRC:

- INMET 2023: 567 membros; 415.560.362 bytes descompactados informados.
- INMET 2024: 565 membros; 405.471.533 bytes descompactados informados.
- INMET 2025: 595 membros, incluindo diretório; 376.671.813 bytes descompactados informados.
- IBGE: cinco membros, incluindo DBF, SHP, SHX, PRJ e CPG.
- CID-10: seis membros; o extrator seleciona quatro tabelas.

Os ZIPs INMET totalizam cerca de 1,20 GB descompactados e contêm estações de outros estados. A Silver filtra SP. Ela aceita CSVs na raiz e também na subpasta 2025/. Presença e metadados não comprovam integridade integral nem aprovação nos DQs.

5 Relação Bronze–Silver

Todos os paths desta seção são relativos a /home/jovyan/work/data.

Transformação	Entradas efetivamente lidas	Gates necessários
Silver SIH	bronze/sih/{ano}/RDSP{AA}{MMDD} e bronze/ibge/2022/SP_Municipios_2022.zip	DQ Bronze SIH e DQ Bronze IBGE
Silver INMET	bronze/inmet/{ano}/{ano}.zip, 2023–2025	DQ Bronze INMET
Silver IBGE	bronze/ibge/2022/SP_Municipios_2022.zip	DQ Bronze IBGE
Silver CID10	Quatro CSVs extraídos em bronze/cid10	DQ Bronze CID10
Silver INMET diário	Silver INMET	DQ Silver INMET, já existente

A função de leitura de municípios em `src/silver/sih.py` abre diretamente o membro `SP_Municipios_2022.dbf` do ZIP IBGE. Portanto, DQ Bronze IBGE deve liberar tanto Silver IBGE quanto Silver SIH. Essa leitura não exige esperar pela transformação Silver IBGE.

6 Estado dos DQs Bronze

Os quatro scripts estão em `src/quality/bronze`. O `common.py` define Report e Check. Não existe nível WARNING nesse modelo: qualquer check falso reprova o relatório.

DQ	Verificações existentes	Limites
<code>dq_sih.py</code>	Competências presentes; tamanho; nome/diretório; conversão DBC para DBF; campos e primeiro registro; duplicidade SHA-256; temporários	Não valida todos os registros nem a competência contida nos dados
<code>dq_inmet.py</code>	ZIPs anuais; tamanho; nome/diretório; CRC; presença de CSVs; cabeçalho e ano em amostra; SHA-256; temporários	Não comprova cobertura completa de SP ou todas as observações
<code>dq_ibge.py</code>	Presença; tamanho; ano; CRC; conjunto SHP/SHX/DBF/PRJ; temporários	Não valida atributos, geometrias, quantidade de municípios ou nome exato exigido por SIH
<code>dq_cid10.py</code>	ZIP e CSVs; tamanhos; CRC; membros esperados; cabeçalhos; igualdade SHA-256 ZIP/extraídos; temporários	Cabeçalho com duas ou mais colunas não comprova schema completo

O DQ SIH converte cada DBC inteiro em DBF temporário, embora examine apenas o primeiro registro depois. O DQ INMET usa `testzip`, percorrendo conteúdo descompactado, e posteriormente calcula hashes dos ZIPs. Não são apenas verificações de existência.

6.1 Falhas e integração com tasks Python

Os quatro `main()` retornam 0 quando aprovados e 1 quando reprovados. Seus blocos de execução usam `SystemExit(main())`. Assim, pela linha de comando, reprovação produz código de saída 1.

Uma task Python que apenas retorne `validar_*`() não falhará automaticamente com um relatório reprovado. Tampouco retornar o inteiro 1 de `main()` equivale a FAILED em PythonOperator. O wrapper futuro deve verificar `report.aprovado` e lançar exceção na reprovação.

Erros inesperados não tratados também podem falhar o processo, possivelmente sem relatório completo. Nenhuma regra foi alterada ou executada nesta auditoria.

7 Idempotência e reprocessamento

Os quatro processos foram classificados como parcialmente idempotentes, considerando falhas e integridade, e não apenas repetição bem-sucedida.

Fonte	Proteções atuais	Fragilidades
SIH	Ignora destino existente; usa .dbc.tmp; promove com replace; limpa temporário nas exceções tratadas	Existente inválido é ignorado; sem timeout explícito ou retomada por byte
INMET	Ignora existente; usa .zip.tmp; download em blocos e promoção	ZIP não validado antes da promoção; ausência de atualização/versionamento
IBGE	Mesmo padrão INMET	Não detecta revisão remota nem recupera arquivo inválido existente
CID-10	Destinos determinísticos; mesmo ZIP reproduz mesmos CSVs após sucesso	Sobrescrita direta por arquivo; extração parcial ou mistura de versões em falha

Riscos comuns dos downloads:

- Existência de arquivo vazio ou corrompido impede nova aquisição automática.
- Interrupção abrupta pode deixar temporário, apesar da limpeza nas exceções tratadas.
- Execuções concorrentes do mesmo destino compartilham o nome temporário.
- Não há comparação com checksum oficial, ETag ou versão remota.
- Não há timeout explícito no código.
- Conteúdo inválido pode chegar ao nome definitivo antes do DQ.
- Retomada reinicia o arquivo incompleto; não continua do último byte.

O lote Bronze SIH para na primeira exceção. Ao repetir, ignora os destinos já presentes. Isso difere do lote Silver SIH, que tenta os demais meses e falha ao final.

Na CID-10, cada CSV é aberto com wb; o conjunto inteiro não é publicado atômicamente. Uma futura recuperação deve definir explicitamente o tratamento de arquivos inválidos antes de substituí-los.

8 Dependências externas e ambiente

Processo	Dependências Python	Recursos externos ou de sistema
Download SIH	urllib e pathlib, biblioteca padrão	FTP, DNS, disco e escrita local
Download INMET/IBGE	urllib, ssl e pathlib	HTTPS, certificados, DNS, disco e escrita local
Extração CID-10	zipfile e pathlib	ZIP local e espaço de saída
DQ SIH	dbfread e pyreaddbf, além da biblioteca padrão	Conversor do pacote e espaço temporário
Outros DQs	Biblioteca padrão	Leitura local, CPU para CRC e hash

Não foi identificada necessidade de requests, PySUS, wget, curl ou Spark para a Bronze atual. Java pertence ao ambiente Spark posterior, não aos coletores Python simples.

Imports somente leitura no worker confirmaram Python 3.11.15, Airflow 3.3.1, provider standard 1.17.0, dbfread 2.0.7, pyreaddbc 2.0.4, airflow.sdk.task, PythonOperator e BashOperator. A importação de dbc2dbf confirmou disponibilidade do módulo, não a execução de uma conversão.

Os volumes já expõem src e data ao worker. Os wrappers precisarão garantir que a raiz do projeto esteja no caminho de imports. Não foram comprovadas conectividade externa ou disponibilidade dos endpoints. Nenhuma instalação foi feita.

9 Proposta de TaskGroups e operators

Recomenda-se manter os cinco TaskGroups existentes e acrescentar aquisição e DQ Bronze aos quatro grupos de fontes.

Grupo	Aquisição/preparação proposta	Gate proposto	Operator
sih	bronze_sih: 36 competências fixas	dq_bronze_sih	@task ou PythonOperator
inmet	bronze_inmet: 2023–2025	dq_bronze_inmet	@task ou PythonOperator
ibge	bronze_ibge: SP/2022	dq_bronze_ibge	@task ou PythonOperator
cid10	bronze_cid10: preparar ZIP provisionado	dq_bronze_cid10	@task ou PythonOperator

Essa alternativa resulta em cinco TaskGroups e 24 tasks. Os decorators podem usar airflow.sdk.task, cuja disponibilidade foi verificada no ambiente instalado. PythonOperator e BashOperator estão disponíveis em airflow.providers.standard.operators.python e airflow.providers.standard.operators.bash.

As funções de aquisição devem executar dentro da task, nunca durante o parse da DAG. Retornos para XCom devem ser pequenos e serializáveis, como strings de paths ou resumos.

BashOperator executando os DQs pela CLI é uma alternativa para preservar o exit code, mas não existe dependência de shell que o torne obrigatório. SparkSubmitOperator permanece para Silver e Gold; a Bronze atual não é um job Spark.

Até esclarecer a origem oficial do ZIP, bronze_cid10 representa preparação local, não aquisição externa totalmente automatizada.

10 Grafo completo proposto

Provisionamento externo CID10

```
-> bronze_cid10 -> dq_bronze_cid10
-> silver_cid10 -> dq_silver_cid10
```

HTTPS IBGE

```
-> bronze_ibge -> dq_bronze_ibge
-> silver_ibge -> dq_silver_ibge
-> silver_sih (também aguarda dq_bronze_sih)
```

FTP SIH: 36 competências

```
-> bronze_sih -> dq_bronze_sih
-> silver_sih (também aguarda dq_bronze_ibge)
-> dq_silver_sih
```

HTTPS INMET: 2023, 2024, 2025

```
-> bronze_inmet -> dq_bronze_inmet
-> silver_inmet -> dq_silver_inmet
-> silver_inmet_diario -> dq_silver_inmet_diario
```

[dq_silver_ibge, dq_silver_inmet]

```
-> gold_municipio_estacao
-> dq_gold_municipio_estacao
```

[dq_silver_sih, dq_silver_ibge, dq_silver_cid10,
dq_gold_municipio_estacao]

```
-> gold_fato_internacao
-> dq_gold_fato_internacao
```

[dq_gold_fato_internacao, dq_silver_inmet_diario]

```
-> gold_fato_internacao_meteorologia
-> dq_gold_fato_internacao_meteorologia
```

As listas entre colchetes exigem sucesso de todos os elementos. Todas as convergências devem utilizar `all_success`. As quatro aquisições/preparações podem executar em paralelo; DQ IBGE libera duas Silver. A concorrência deve respeitar CPU, memória, disco e rede do ambiente local.

11 Estratégia de retries proposta

Processo	Retries	Delay inicial	Observação
Aquisição SIH	3	2 minutos	Backoff exponencial; teto sugerido de 10 minutos
Aquisição INMET	2	2 minutos	Limitar concorrência de arquivos maiores
Aquisição IBGE	2	1 minuto	Referência pequena e estável
Extração CID-10	0	Não aplicável	Repetição não corrige ZIP ausente/corrompido
DQs Bronze	0	Não aplicável	Reprovação exige diagnóstico
Silver/Gold existentes	Preservar	Preservar	Transformações 1; DQs 0

Os números são propostas, não resultados medidos. Rede transitória, como timeout ou reset, pode justificar retry. Dados inválidos, argumentos incorretos, imports ausentes e falhas de código não devem ser repetidos indiscriminadamente.

Parte dos erros de aquisição é encapsulada atualmente em `RuntimeError`. O wrapper e o tratamento futuro precisam preservar a causa para distinguir falhas transitórias de erros permanentes.

12 Incrementalidade e as 36 competências SIH

Recomenda-se garantir a presença e integridade do acervo fixo 2023–2025, baixando ausentes, em vez de refazer todos os downloads. Apenas `exists()` não distingue um arquivo válido de um inválido.

Unidade SIH	Vantagem	Custo
Uma task para 36 meses	Reutiliza <code>download_sih_periodo</code> ; menor mudança	Retry agregado; primeira falha interrompe o restante
Uma task por competência	Isolamento e retomada precisos	Mais tasks e controle de concorrência
Uma task por ano	Três unidades simples	Ainda agrega 12 meses por retry

Para a primeira integração, recomenda-se uma task para o período completo, aproveitando a função existente e o acervo já presente. Os parâmetros devem fixar janeiro/2023 a dezembro/2025. O DQ SIH possui defaults de fim baseados na data atual; não devem ser usados para o recorte do TCC.

Se a coleta se tornar recorrente, a competência é a unidade natural futura, com poucas aquisições simultâneas. Não se recomenda disparar 36 downloads concorrentes. Dynamic task mapping não foi implementado.

Arquivo válido já disponível deve resultar em sucesso. Marcar esse caso como `SKIPPED` pode bloquear etapas seguintes sob `all_success`. Evitar reprocessamento Silver/Gold por ausência de mudanças exigiria uma política adicional de dependências e invalidação, não apenas pular o download.

13 Problemas e ambiguidades encontrados

1. CID-10 sem aquisição externa implementada ou origem/versionamento comprovados.
2. SIH, INMET e IBGE sem CLI que execute suas funções de download.
3. Retorno de relatório ou inteiro não falha automaticamente uma task Python.
4. Dependência Bronze IBGE para Silver SIH precisa constar na DAG.
5. DQ IBGE valida conjunto shapefile, mas não o nome exato do DBF exigido por SIH.
6. DQ SIH possui defaults temporais móveis, inadequados ao recorte fixo sem argumentos explícitos.
7. Arquivos existentes inválidos são ignorados pelos coletores.
8. Extração CID-10 não publica o conjunto de CSVs atomicamente.
9. Temporários são pesquisados em toda a raiz da fonte, inclusive fora do recorte solicitado.
10. Ausência de versão ou hash persistido para detectar revisão silenciosa das fontes.
11. Diferença já documentada na Gold: leitura recursiva de silver/ibge versus gates sobre silver/ibge/2022.

Esses pontos foram registrados sem correções especulativas. O comportamento dos DQs foi determinado por leitura do código, não por aprovação dos datasets durante a auditoria.

14 Segurança dos dados e implementação futura

Não foram apagados, movidos ou sobrescritos dados. Não houve mudanças de permissões, Dockerfiles, requirements, Docker Compose, connection, commit ou push. Os imports foram feitos com python -B para evitar geração de bytecode.

Antes de implementar recuperação automática de arquivos corrompidos, deve-se definir uma política explícita de substituição e preservação da fonte. Downloads para o mesmo destino não devem competir pelo mesmo temporário. Extração CID-10 deve considerar publicação segura do conjunto, sem transformar a auditoria em autorização para sobrescrever dados existentes.

15 Impacto provável no tempo de execução

Os 45 minutos são o baseline informado para as 16 tasks atuais. Com o acervo existente, os downloads devem ser evitados, mas os DQs ainda acrescentam custo:

- SIH: 36 conversões DBC para DBF e cerca de 665 MB de leitura para hashes.
- INMET: CRC de cerca de 1,20 GB descompactados, amostras e hashes dos ZIPs.
- IBGE e CID-10: tendência de custo menor pelo volume, ainda sem medição.

Uma aquisição inicial das fontes exigiria aproximadamente 977 MB de transferência pelos tamanhos atuais, excluindo os CSVs CID-10 extraídos. Rede, disco e sobreposição dos ramos determinam o acréscimo real. Não é possível estimar minutos com segurança por análise estática.

15.1 Cinco oportunidades simples para investigar

Prioridade	Oportunidade	Avaliação pragmática
1	Evitar downloads repetidos de fontes válidas	Comparar acervo presente com aquisição de um arquivo ausente
2	Reduzir varreduras repetidas nos DQs	Medir cada gate e agrupar métricas compatíveis preservando regras
3	Revisar recomputações Gold	Investigar actions repetidas e cache pontual com controle de memória
4	Reutilizar preparação auxiliar IBGE no lote SIH	Medir preparação uma vez por lote, preservando resultados
5	Ajustar concorrência dos ramos independentes	Comparar tempo total e pressão de recursos com limites simples

Há evidência estática de várias actions em src/common/validators.py e nas duas fatos Gold. A revisão não recomenda remover verificações críticas para ganhar tempo.

Broadcast, AQE e reparticionamento não são a primeira prioridade. A fato já possui broadcast automático desativado por motivo de memória; a fato meteorológica usa repartition e partitionBy por ano/mês. Alterações nesses pontos exigem medição e cuidado adicional.

16 Próxima etapa recomendada

Primeiro, preparar wrappers de aquisição e DQ, recorte temporal fixo, timeouts, classificação de falhas e política para arquivos inválidos. Manter CID-10 como insumo provisionado até esclarecer a origem.

Depois, adicionar oito tasks Bronze/DQ à DAG e a dependência DQ Bronze IBGE para Silver SIH, preservando as 16 tasks existentes. Validar inicialmente com o acervo atual, sem forçar downloads ou sobrescritas, e medir separadamente os quatro gates Bronze.

17 Evidências e limitações da auditoria

Foram consultados `src/bronze`, `src/quality/bronze`, consumidores Silver, código Gold e validadores comuns, DAG, configurações Docker, requirements, README, notebook de validação e a estrutura `data/bronze`. Foram usados `rg`, leitura de arquivos, listagens, metadados de ZIP e imports leves no worker.

Não foram feitos downloads, testes de conectividade, descompactação integral, conversões, hashes integrais dos datasets, execução dos DQs ou pipeline. Não foi feita pesquisa externa de endpoints. O estado Git consultado ao final da auditoria estava sem alterações.

Este documento registra o estado observado na auditoria; não é evidência de aprovação integral dos dados nem de integração Bronze já implementada.