

Implementação da camada de consumo para Power BI

TCC — integração de saúde e meteorologia

14 de setembro de 2026

Sumário

1	Resumo executivo	2
2	Escopo implementado	2
2.1	Datasets criados	2
2.2	Código criado	2
2.3	Código alterado	2
3	Arquitetura final	2
4	Recorte temporal	3
5	Resultados materializados	3
5.1	Particionamento	3
6	Schema de fato_municipio_dia	3
7	Schema de fato_municipio_dia_cid	4
7.1	Tratamento da idade	5
7.2	Hierarquia CID	5
8	Schemas das dimensões	5
8.1	dim_municipio	5
8.2	dim_cid	5
8.3	dim_tempo	6
8.4	dim_estacao	6
9	Meteorologia adicional	6
9.1	Regras de agregação	6
9.2	Cobertura observada	7
10	Lags de temperatura	7
11	Reconciliação das métricas de saúde	7
12	Data Quality	7
12.1	Resultado	8
13	Testes automatizados	8
14	Integração com a DAG	8
15	Decisões técnicas	9
15.1	Separação dos fatos	9
15.2	Dias sem internação	9

15.3 Valores financeiros	9
15.4 Processamento da Gold ampla	9
16 Estado do Git	9
17 Conclusão	10

1 Resumo executivo

Foi implementada e materializada a camada `data/consumption/` para consumo no Power BI. A solução contém duas tabelas fato e quatro dimensões, considera exclusivamente internações com `data_internacao` entre 01/01/2023 e 31/12/2025 e preserva as camadas Bronze, Silver e Gold existentes.

As duas fatos reconciliam exatamente **8.236.990 internações, 422.557 óbitos, 39.845.279 dias de permanência e 488.421 dias de UTI**. Os valores financeiros também coincidem integralmente entre as duas fatos e a Gold de origem.

A implementação acrescenta agregações diárias de radiação, pressão atmosférica, temperatura de orvalho e rajada de vento diretamente da Silver INMET horária. Também oferece temperatura média com defasagens exatas de 1, 3 e 7 dias.

O Data Quality terminou com status **PASS**. Os oito testes sintéticos foram aprovados. A DAG foi importada sem erros e recebeu o novo TaskGroup `consumption`.

Nenhum commit foi realizado.

2 Escopo implementado

2.1 Datasets criados

Dataset	Grão
<code>fato_municipio_dia</code>	Data de internação + município
<code>fato_municipio_dia_cid</code>	Data + município + categoria CID + sexo + faixa etária
<code>dim_municipio</code>	Município
<code>dim_cid</code>	Categoria CID
<code>dim_tempo</code>	Dia de calendário
<code>dim_estacao</code>	Estação meteorológica

2.2 Código criado

- `src/consumption/transformations.py`: transformações reutilizáveis e testáveis.
- `src/consumption/build.py`: leitura das fontes, construção e gravação dos seis datasets.
- `src/quality/consumption/dq_consumption.py`: regras de qualidade e reconciliação.
- `tests/test_consumption.py`: testes unitários com DataFrames sintéticos.
- Arquivos `__init__.py` para os novos pacotes.


2.3 Código alterado


- `dags/tcc_pipeline.py`: inclusão da configuração, caminhos, TaskGroup e dependências da camada de consumo.

Não foram alteradas regras Bronze, Silver ou Gold. Não foram removidos datasets existentes, criadas conexões, alteradas portas ou modificadas configurações do Docker Compose como parte desta implementação.

3 Arquitetura final

O fluxo acrescentado ao pipeline é:





As fontes Silver necessárias somente alimentam a transformação depois de seus respectivos gates de qualidade. A transformação também aguarda a aprovação de gold.dq_gold_fato_internacao_meteorologia.

4 Recorte temporal

O filtro analítico utiliza somente:

```
data_internacao >= 2023-01-01
data_internacao <= 2025-12-31
```

As colunas ano e mes de competência SIH não são usadas para selecionar as internações. A coluna física ano das novas fatos é novamente derivada da data analítica e serve exclusivamente ao particionamento.

5 Resultados materializados

Dataset	Linhas	Arquivos Parquet	Tamanho aproximado	Partições físicas
fato_municipio_dia	578.832	3	26,98 MB	ano
fato_municipio_dia_cid	6.597.066	3	113,40 MB	ano
dim_municipio	645	1	35,65 KB	Nenhuma
dim_cid	1.658	1	69,42 KB	Nenhuma
dim_tempo	1.096	1	13,05 KB	Nenhuma
dim_estacao	40	1	3,63 KB	Nenhuma

5.1 Particionamento

As fatos são particionadas por ano da data analítica, resultando em apenas três partições: 2023, 2024 e 2025. Essa escolha permite leitura por período no Power BI e evita uma árvore mensal com muitos arquivos pequenos.

As dimensões são pequenas e foram gravadas em um arquivo cada, sem particionamento físico.

6 Schema de fato_municipio_dia

Campo	Tipo
municipio_dia_id	string
data	date
codigo_municipio	string
codigo_estacao	string
qtd_internacoes	bigint
qtd_obitos	bigint
dias_permanencia_total	bigint
dias_uti_total	bigint
valor_total_internacoes	decimal(20,2)
valor_total_uti	decimal(20,2)
temperatura_media_dia_c	double
temperatura_minima_dia_c	double
temperatura_maxima_dia_c	double

Campo	Tipo
umidade_media_dia_pct	double
umidade_minima_dia_pct	double
umidade_maxima_dia_pct	double
precipitacao_dia_mm	double
vento_medio_dia_ms	double
vento_maximo_dia_ms	double
qtd_observacoes_inmet	bigint
qtd_obs_temperatura	bigint
qtd_obs_umidade	bigint
qtd_obs_precipitacao	bigint
qtd_obs_vento	bigint
meteorologia_disponivel	int
motivo_sem_meteorologia	string
radiacao_global_dia_kj_m2	double
qtd_obs_radiacao	bigint
pressao_media_dia_mb	double
pressao_minima_dia_mb	double
pressao_maxima_dia_mb	double
qtd_obs_pressao	bigint
orvalho_medio_dia_c	double
orvalho_minimo_dia_c	double
orvalho_maximo_dia_c	double
qtd_obs_orvalho	bigint
rajada_maxima_dia_ms	double
qtd_obs_rajada	bigint
temperatura_media_lag_1d	double
temperatura_media_lag_3d	double
temperatura_media_lag_7d	double
ano	int — partição física

A chave `municipio_dia_id` segue o formato `AAAAMDD_codigo_municipio`, por exemplo `20240115_3509502`.

As taxas e médias não são armazenadas. A tabela preserva numeradores e denominadores para que o Power BI calcule mortalidade, permanência média e valor médio no contexto de filtro correto.

7 Schema de fato_municipio_dia_cid

Campo	Tipo
municipio_dia_id	string
data	date
codigo_municipio	string
codigo_categoria	string
sexo	string
faixa_etaria	string
qtd_internacoes	bigint
qtd_obitos	bigint
dias_permanencia_total	bigint
dias_uti_total	bigint
valor_total_internacoes	decimal(20,2)
valor_total_uti	decimal(20,2)
ano	int — partição física

Nenhum campo meteorológico foi duplicado nessa tabela. A relação com a meteorologia ocorre por `municipio_dia_id` ou pelas

dimensões de data e município, conforme o modelo Power BI adotado.

7.1 Tratamento da idade

A faixa etária foi construída a partir de COD_IDADE e IDADE da Silver SIH:

COD_IDADE	Interpretação
2	Idade em dias; faixa 0–17
3	Idade em meses; faixa 0–17
4	Idade em anos
5	100 + IDADE; faixa 80+
0 ou código inválido	Ignorada

As categorias finais são 0-17, 18-39, 40-59, 60-79, 80+ e Ignorada. A categoria Ignorada preserva o registro e mantém a reconciliação dos totais.

7.2 Hierarquia CID

A Silver SIH fornece o diagnóstico principal. A categoria é obtida por meio do mapeamento `codigo_cid` → `codigo_categoria` efetivamente resolvido pela Gold, incluindo suas regras de compatibilidade e fallback. A reconstrução não apresentou diagnóstico sem categoria no recorte.

8 Schemas das dimensões

8.1 dim_municipio

Campo	Tipo
<code>codigo_municipio</code>	string
<code>codigo_municipio_sih</code>	string
<code>nome_municipio</code>	string
<code>sigla_uf</code>	string
<code>area_km2</code>	double
<code>latitude_municipio</code>	double
<code>longitude_municipio</code>	double
<code>codigo_estacao_referencia</code>	string
<code>distancia_estacao_km</code>	double
<code>ano_referencia_ibge</code>	int

8.2 dim_cid

Campo	Tipo
<code>codigo_categoria</code>	string
<code>descricao_categoria</code>	string
<code>cat_inicial_grupo</code>	string
<code>cat_final_grupo</code>	string
<code>codigo_grupo</code>	string
<code>descricao_grupo</code>	string
<code>codigo_capitulo</code>	string
<code>descricao_capitulo</code>	string

`codigo_grupo` é formado pelos limites inferior e superior do grupo, como J00-J06. A dimensão contém 1.658 categorias únicas e reflete a hierarquia resolvida da Gold.

8.3 dim_tempo

Campo	Tipo
data	date
data_id	int
ano	int
mes	int
nome_mes	string
ano_mes	string
trimestre	int
dia_mes	int
dia_semana_numero	int
dia_semana_nome	string
fim_de_semana	boolean

O calendário é contínuo de 01/01/2023 a 31/12/2025, com 1.096 dias. A dimensão não converte automaticamente dias ausentes da fato em zero interações.

8.4 dim_estacao

Campo	Tipo
codigo_estacao	string
nome_estacao	string
latitude_estacao	double
longitude_estacao	double
uf	string
regiao	string
altitude_m	double

A consistência histórica foi verificada antes da deduplicação. Dez estações apresentam revisões de nome, coordenadas ou altitude entre 2023 e 2025. UF e região são estáveis. Como o schema solicitado não prevê vigência temporal, a dimensão usa deterministicamente o cadastro mais recente, de 2025, e o DQ registra a situação como aviso.

9 Meteorologia adicional

9.1 Regras de agregação

Campo horário da Silver	Indicador diário	Agregação
radiacao_global_kj_m2	radiacao_global_dia_kj_m2	Soma
pressao_estacao_mb	pressão média, mínima e máxima	Média, mínimo e máximo
temperatura_orvalho_c	orvalho médio, mínimo e máximo	Média, mínimo e máximo
vento_rajada_max_ms	rajada_maxima_dia_ms	Máximo

radiacao_global_kj_m2 representa energia global por área acumulada no intervalo horário. Portanto, a soma dos intervalos válidos é semanticamente adequada para a energia diária. O contador qtd_obs_radiacao deve sempre acompanhar a análise para revelar dias parciais.

Não foi calculada média aritmética de vento_direcao_graus.

9.2 Cobertura observada

Denominador: 578.832 combinações município-dia existentes.

Indicador	Linhas preenchidas	Cobertura
Radiação global diária	507.681	87,71%
Pressão média/mínima/máxima	530.298	91,62%
Orvalho médio/mínimo/máximo	520.477	89,92%
Rajada máxima	480.934	83,09%

Os contadores das quatro famílias adicionais estão presentes em todas as 578.832 linhas. Um contador zero indica ausência de observação válida, sem transformar o valor meteorológico nulo em erro de qualidade.

10 Lags de temperatura

Foram criados:

- temperatura_media_lag_1d;
- temperatura_media_lag_3d;
- temperatura_media_lag_7d.

Cada valor é obtido pela igualdade entre estação e data civil exata:

```
lag_1d = temperatura em data - 1 dia  
lag_3d = temperatura em data - 3 dias  
lag_7d = temperatura em data - 7 dias
```

Não foi utilizada a linha anterior de uma janela. A busca consulta a Silver INMET diária, mesmo quando não existe interseção na data do lag. Quando a data ou a medição não existe, o resultado permanece nulo. Nenhum valor de dezembro de 2022 foi inventado.

11 Reconciliação das métricas de saúde

Métrica	Gold 2023–2025	Fato município-dia	Fato município-dia-CID
Internações	8.236.990	8.236.990	8.236.990
Óbitos	422.557	422.557	422.557
Dias de permanência	39.845.279	39.845.279	39.845.279
Dias de UTI	488.421	488.421	488.421
Valor total	R\$ 14.389.294.434,48	R\$ 14.389.294.434,48	R\$ 14.389.294.434,48
Valor de UTI	R\$ 3.821.109.214,10	R\$ 3.821.109.214,10	R\$ 3.821.109.214,10

Os valores monetários foram convertidos para `decimal(20,2)` antes da soma, evitando diferenças de representação binária próprias de `double`.

12 Data Quality

O script `src/quality/consumption/dq_consumption.py` valida:

1. schema mínimo das duas fatos;
2. unicidade de `municipio_dia_id` na fato diária;
3. unicidade da chave completa na fato CID;
4. ausência de chaves obrigatórias nulas ou vazias;
5. `qtd_internacoes > 0`;
6. óbitos entre zero e internações;
7. reconciliação das seis métricas de saúde com a Gold;

8. igualdade dos totais entre as duas fatos;
9. domínio das faixas etárias;
10. integridade referencial com as quatro dimensões;
11. unicidade das chaves dimensionais;
12. calendário contínuo e período correto;
13. ausência de meteorologia na fato CID;
14. unicidade meteorológica por data e município;
15. limites dos contadores horários;
16. preservação dos contadores vindos da Gold;
17. correspondência exata dos lags com suas datas;
18. cobertura informativa das variáveis adicionais;
19. consistência histórica do cadastro de estações.

12.1 Resultado

STATUS FINAL: PASS

Resultados relevantes:

- zero duplicidades nas duas fatos;
- zero chaves obrigatórias nulas;
- zero chaves ausentes nas dimensões;
- zero divergências nos totais de saúde;
- zero contadores fora do intervalo 0–24;
- zero divergências em cada um dos três lags;
- um aviso não bloqueante sobre as dez estações com metadados revisados.

13 Testes automatizados

Foram criados oito testes com pequenos DataFrames sintéticos:

- conversão de COD_IDADE + IDADE em faixa etária;
- criação da chave municipio_dia_id;
- agregação dos numeradores de saúde;
- agregações meteorológicas adicionais;
- lags por data exata em série esparsa;
- hierarquia CID resolvida;
- calendário contínuo;
- fluxo integrado das principais regras de DQ.

Resultado:

Ran 8 tests in 18.818s

OK

A suíte foi executada com Spark 3.5.0. Os avisos de sockets emitidos pelo runtime Python após ações Spark não causaram falhas nos testes.

14 Integração com a DAG

Foi adicionado o TaskGroup consumption, com duas tasks SparkSubmitOperator:

Task	Função
consumption.build_consumption	Materializa as duas fatos e quatro dimensões
consumption.dq_consumption	Valida os datasets materializados

Dependências confirmadas pela DAG carregada:

```
gold.dq_gold_fato_internacao_meteorologia ┌
inmet.dq_silver_inmet                  │→ consumption.build_consumption
inmet.dq_silver_inmet_diario            │
sih.dq_silver_sih                       └
```

```
consumption.build_consumption
-> consumption.dq_consumption
```

A conexão permanece `spark_default`; nenhuma conexão foi criada ou alterada. As novas tasks utilizam 40 partições de shuffle, como a Gold meteorológica.

Durante a materialização real, o heap padrão de 1 GiB foi insuficiente para as agregações das duas fatos. As tasks de consumo receberam `spark.driver.memory = 4g`. Essa configuração é exclusiva do novo TaskGroup e não altera `spark_default` nem as tasks existentes.

A DAG passou na validação de importação:

```
airflow dags list-import-errors --output json
[]
```

15 Decisões técnicas

15.1 Separação das fatos

A meteorologia permanece em `fato_municipio_dia`, onde é única por data e município. A fato CID contém somente métricas de saúde. Isso evita replicar indicadores meteorológicos a cada categoria, sexo e faixa etária.

15.2 Dias sem internação

A dimensão de tempo contém todos os dias, mas as fatos contém apenas combinações observadas. A implementação não presume que ausência de linha significa zero internações.

15.3 Valores financeiros

Os campos representam valores registrados no SIH. O schema preserva `valor_total_internacoes` e `valor_total_uti` separadamente; a camada não soma os dois nem os interpreta como custo econômico completo.

15.4 Processamento da Gold ampla

A saúde é agregada separadamente das colunas meteorológicas. A combinação meteorológica única é reduzida ao grão municipal diário e depois unida aos totais de saúde. A equivalência foi garantida pelo DQ.

16 Estado do Git

Nenhum commit foi realizado. O `git diff --stat` dos arquivos rastreados no momento da entrega era:

```
dags/tcc_pipeline.py          | 57 ++++++
docker-compose.airflow.yaml   |  2 +-
src/gold/fato_internacao_meteorologia.py | 43 ++++++
3 files changed, 101 insertions(+), 1 deletion(-)
```

O `git diff --stat` não inclui arquivos ainda não rastreados. As modificações de `docker-compose.airflow.yaml` e `src/gold/fato_internacao_meteorologia.py` já existiam antes desta implementação e não foram alteradas durante o trabalho da camada de consumo.

Estado completo observado:

```
M dags/tcc_pipeline.py
M docker-compose.airflow.yaml
M src/gold/fato_internacao_meteorologia.py
```

```
?? docs/Relatorio_Auditoria_Camada_Consumo_Power_BI.md
?? docs/Relatorio_Auditoria_Camada_Consumo_Power_BI.pdf
?? docs/Relatorio_Experimento_2_Persistencia_INMET.md
?? docs/Relatorio_Experimento_2_Persistencia_INMET.pdf
?? docs/Relatorio_Resultados_Performance_Experimentos_1_2.md
?? docs/Relatorio_Resultados_Performance_Experimentos_1_2.pdf
?? src/consumption/
?? src/quality/consumption/
?? tests/test_consumption.py
?? tests/test_fato_meteorologia_persistencia.py
```

17 Conclusão

A camada de consumo está implementada, materializada e validada. O modelo oferece o grão diário municipal para meteorologia e totais de saúde, além do detalhamento por categoria CID, sexo e faixa etária para as análises do Power BI.

Os totais são reconciliados com a Gold, a idade respeita a unidade SIH, os lags utilizam datas civis exatas e as lacunas meteorológicas permanecem explícitas por meio dos indicadores nulos e contadores de observações.

Status final: implementação concluída; DQ aprovado; testes aprovados; nenhuma alteração nas regras Bronze, Silver ou Gold; nenhum commit criado.