

Integração Bronze e Data Quality ao Airflow

9 de setembro de 2026

Sumário

1	Resultado e baseline	1
2	Arquivos e implementação	1
3	Execução e parâmetros efetivos	2
4	Arquivos existentes e particularidade CID-10	2
5	Retries e paralelismo	3
6	Grafo completo	3
7	Testes e resultados	4
8	Estatísticas e resumo do diff	5
9	Riscos e limitações	5

1 Resultado e baseline

A DAG `tcc_pipeline` passou de 16 para 24 tasks, mantendo os cinco TaskGroups `inmet`, `ibge`, `cid10`, `sih` e `gold`. Foram adicionadas oito PythonOperators nos quatro grupos de fonte. O grupo Gold permaneceu estruturalmente igual. Não houve execução da DAG completa.

O baseline operacional informado pelo usuário é uma execução das 16 tasks anteriores em SUCCESS, com cerca de 45 minutos. Não se repetiu essa execução. As configurações e dependências entre essas 16 tasks foram comparadas programaticamente com a DAG em HEAD e preservadas.

Antes da implementação, foram relidos os coletores, DQs, DAG e paths dos consumidores. Confirmou-se que Silver SIH lê diretamente o ZIP Bronze IBGE/2022. Os relatórios de auditoria Bronze já existentes como arquivos não rastreados foram preservados.

2 Arquivos e implementação

Arquivo existente modificado: `dags/tcc_pipeline.py`. Foram acrescentados import de PythonOperator, acesso ao módulo de wrappers pela raiz montada do projeto, oito operadores, retries e nove novas arestas. Nenhuma configuração Spark existente foi alterada.

Arquivos de código criados:

- `src/orchestration/init.py`: identificação do pacote.
- `src/orchestration/bronze.py`: quatro wrappers de aquisição/preparação, quatro de DQ e um helper de aprovação.
- `tests/test_bronze_orchestration.py`: cinco testes automatizados leves.

Também foram criados este relatório Markdown e sua versão PDF. Não houve alteração em scripts Bronze originais, regras DQ, Silver, Gold, Docker, requirements, connection ou permissões.

3 Execução e parâmetros efetivos

Wrapper	Função reutilizada	Parâmetros
bronze_sih	download_sih_periodo	ano_inicio=2023, mes_inicio=1, ano_fim=2025, mes_fim=12
bronze_inmet	download_inmet	Chamadas para 2023, 2024 e 2025
bronze_ibge	download_malha_sp_2022	Referência fixa do coletor: SP/2022
bronze_cid10	extrair_cid10, quando necessário	ZIP local provisionado; somente destinos ausentes
dq_bronze_sih	validar_sih	2023-01 até 2025-12, todos os argumentos explícitos
dq_bronze_inmet	validar_inmet	ano_inicio=2023, ano_fim=2025
dq_bronze_ibge	validar_ibge	ano=2022
dq_bronze_cid10	validar_cid10	Raiz atual definida pelo validador

Imports dos coletores e validadores são locais às funções dos wrappers. Nenhuma aquisição ou validação é chamada no parse da DAG. Os retornos da aquisição são strings ou listas de strings de caminhos, adequados à serialização. Os DQs imprimem o relatório e retornam normalmente apenas quando aprovados.

Cada wrapper DQ chama a função real de validação, imprime os checks e lança `ValueError` quando `report.aprovado` é falso. Não utiliza o retorno inteiro de `main` como mecanismo de falha. Com `retries=0` e `all_success` nos consumidores, um DQ reprovado impede a execução da Silver dependente. A transição de estado em uma DAG Run real ainda será observada pelo usuário.

4 Arquivos existentes e particularidade CID-10

SIH, INMET e IBGE mantêm o comportamento dos coletores: destino existente é reutilizado, sem novo download. Nenhuma recuperação automática foi adicionada. Arquivo existente inválido permanece disponível para diagnóstico e pode reprovar no DQ.

O extrator CID-10 original abre CSVs com `wb`. Chamá-lo diretamente sobre a Bronze contrariaria a restrição de não sobrescrever. O wrapper implementa a adaptação mínima:

1. Verifica se o ZIP local existe; se não existir, lança `FileNotFoundError` com mensagem explícita.
2. Preserva CSVs existentes, inclusive inválidos, para o gate posterior.
3. Quando há CSVs ausentes, reutiliza o extrator original em diretório temporário isolado.
4. Copia somente os ausentes para a Bronze com abertura exclusiva `xb`, impedindo sobrescrita de destino que surja nesse intervalo.

Quando os quatro CSVs existem, não há reextração. Não foi criada URL ou aquisição externa CID-10. O comportamento do extrator original fora deste wrapper permanece inalterado.

A publicação de arquivos novos não é atômica para o conjunto inteiro: uma interrupção durante a cópia pode deixar um arquivo novo parcial. O wrapper não o apaga ou recupera automaticamente; ele permanece para diagnóstico. O staging temporário é limpo pelo gerenciador de contexto, sem mover ou limpar datasets existentes.

5 Retries e paralelismo

Task	Retries	Retry delay configurado
sih.bronze_sih	3	2 minutos
inmet.bronze_inmet	2	2 minutos
ibge.bronze_ibge	2	1 minuto
cid10.bronze_cid10	0	Sem override; sem retry
Quatro DQs Bronze	0	Sem override; sem retry
Transformações Silver/Gold	1	Configuração anterior preservada
DQs Silver/Gold	0	Configuração anterior preservada

As quatro aquisições não possuem upstreams e podem começar independentemente. Não foram adicionados backoff, pools, tuning ou dependências artificiais. Uma única task Bronze SIH cobre as 36 competências, mantendo interrupção na primeira falha do coletor de período. Não foi utilizado dynamic task mapping.

6 Grafo completo

```
inmet:
  bronze_inmet -> dq_bronze_inmet
  -> silver_inmet -> dq_silver_inmet
  -> silver_inmet_diario -> dq_silver_inmet_diario

ibge:
  bronze_ibge -> dq_bronze_ibge
  -> silver_ibge -> dq_silver_ibge

cid10:
  bronze_cid10 -> dq_bronze_cid10
  -> silver_cid10 -> dq_silver_cid10

sih:
  bronze_sih -> dq_bronze_sih
  -> silver_sih -> dq_silver_sih
```

Dependência cruzada adicional:
ibge.dq_bronze_ibge -> sih.silver_sih

gold:
[dq_silver_ibge, dq_silver_inmet]
-> gold_municipio_estacao
-> dq_gold_municipio_estacao

[dq_silver_sih, dq_silver_ibge, dq_silver_cid10,
dq_gold_municipio_estacao]
-> gold_fato_internacao
-> dq_gold_fato_internacao

[dq_gold_fato_internacao, dq_silver_inmet_diario]
-> gold_fato_internacao_meteorologia
-> dq_gold_fato_internacao_meteorologia

Silver SIH exige simultaneamente DQ Bronze SIH e DQ Bronze IBGE. A dependência vem da leitura direta de data/bronze/ibge/2022/SP_Municipios_2022.zip. Todos os trigger rules foram verificados como all_success. O grafo não possui ciclos.

7 Testes e resultados

Comando principal no worker:

```
docker compose -f docker-compose.airflow.yaml exec -T  
-w /home/jovyan/work airflow-worker  
python -B -m unittest discover -s tests  
-p test_bronze_orchestration.py -v
```

As quebras são apenas de apresentação. Resultado: cinco testes executados, todos OK, sem skips.

Teste	Resultado
Períodos de aquisição	36 chamadas mensais SIH exatas; INMET 2023, 2024, 2025; função IBGE correta
Gates	Quatro reprovações simuladas lançam ValueError; quatro aprovações concluem; parâmetros DQ conferidos
CID-10 em fixture temporária	CSV divergente preservado; ausentes criados; segunda chamada não reextrai; ZIP ausente falha claramente
Acervo real existente	Wrappers de aquisição executados com chamadas de rede bloqueadas por mocks; extrator CID-10 também bloqueado; tamanho e mtime dos arquivos preservados
DAG	Cinco grupos, 24 tasks, retries/delays, upstreams/downstreams exatos, all_success e ordenação topológica aprovados; wrappers não chamados no parse

Verificações adicionais:

- compile em memória da DAG, pacote de wrappers e teste: PASS.
- Imports no worker, exercitados pelos testes e importação da DAG: PASS.
- Comparação com a DAG em HEAD: 16 tasks anteriores mantêm application, conf, retries, retry_delay, connection, name, trigger_rule e arestas entre si: PASS.
- airflow dags list-import-errors: No data found.
- git diff -check: sem erros; somente aviso de normalização LF/CRLF.
- Revisão integral do diff e dos novos arquivos: escopo restrito à integração, testes e documentação.

Os testes de aquisição não apagaram arquivos para provocar downloads. O teste CID-10 que cria CSVs usa exclusivamente um diretório temporário de teste. Os DQs reais de grande volume não foram executados; suas funções foram substituídas por relatórios simulados apenas no processo do teste, sem editar as regras.

8 Estatísticas e resumo do diff

O comando git diff -stat apresentou:

```
dags/tcc_pipeline.py | 66 ++++++++++++++++++++++++++++++++++++++++++++++++++++++
1 file changed, 66 insertions(+)
```

Arquivos novos não rastreados não entram nessa estatística: pacote src/orchestration, teste e relatórios. Os documentos da auditoria anterior já estavam presentes e não foram alterados nesta implementação.

As 66 linhas da DAG acrescentam imports/acesso ao módulo, oito operadores e nove arestas. O wrapper concentra recorte fixo, execução runtime, reprovação DQ por exceção e proteção contra sobrescrita CID-10. Os testes verificam o contrato da integração. Não houve modificação de algoritmos, paths dos datasets, granularidade, regras DQ, shuffle, broadcast, cache, persist ou actions.

9 Riscos e limitações

Os coletores continuam confiando em existência, sem recuperação de conteúdo inválido. Seus timeouts, tratamento de rede e comportamento de falha não foram reescritos. O lote Bronze SIH continua interrompendo na primeira falha.

CID-10 continua dependendo do ZIP provisionado, sem origem externa automatizada. Se o ZIP for inválido e todos os CSVs já existirem, a preparação preserva os arquivos e o DQ deve diagnosticar a inconsistência. Se faltarem CSVs, a extração pode falhar antes do gate.

Os DQs Bronze mantêm seus custos anteriores: conversão temporária de DBC, CRC e hashes. Nenhuma otimização ou estimativa nova de duração foi aplicada. O baseline de 45 minutos não inclui estas oito tasks.

Não foi disparada a DAG de 24 tasks, nem testada aquisição real de arquivo ausente na rede. O estado FAILED no Airflow, resultados integrais dos DQs, tempo total e comportamento operacional de retries serão observados na execução manual posterior. Nenhum commit ou push foi feito.