

Integração da camada Gold ao Apache Airflow

Auditoria, refatoração de runtime e validação da DAG

9 de setembro de 2026

Sumário

1	Resultado e estado inicial	1
2	Auditoria dos datasets e dependências	2
2.1	Entradas dos DQs	2
2.2	Ambiguidade preservada	2
3	Auditoria Spark e transferência de configurações	2
3.1	Configuração final das seis tasks	3
4	Arquivos modificados e criados	3
5	Grafo final da DAG	4
6	Validações executadas	4
7	Estatísticas Git e resumo do diff	5
8	Limitações, riscos e validação operacional pendente	6

1 Resultado e estado inicial

A DAG `tcc_pipeline` foi ampliada de quatro TaskGroups e dez tasks para cinco TaskGroups e 16 tasks. O novo grupo `gold` contém três transformações e seus três gates de qualidade. Cada transformação aguarda os gates de todas as fontes identificadas no código.

O usuário informou que a execução completa das dez tasks `Silver/DQ`, após a refatoração anterior, terminou em `SUCCESS`. Essa informação constitui o baseline operacional informado; nesta tarefa não se repetiu a execução de datasets.

O repositório já apresentava mudanças não commitadas da refatoração `Silver` e seus relatórios. Elas foram preservadas. Antes de editar, foi salvo um snapshot textual em `/tmp` no worker para comparação com o estado inicial desta tarefa. O diff contra `HEAD` inclui também essas alterações anteriores e não deve ser confundido com o incremento `Gold`.

Foram encontrados três scripts em `src/gold` e três DQs, `common.py`, `quality_config.py` e `init.py` em `src/quality/gold`. A DAG utiliza `SparkSubmitOperator`, `spark_default`, `retries 1` nas transformações,

retries 0 nos DQs e durable=False. A stack declarada no projeto é Airflow 3.3.1, provider Spark 6.3.2, PySpark 3.5.0, Python 3.11 e Java 17.

2 Auditoria dos datasets e dependências

Todos os caminhos abaixo são relativos a /home/jovyan/work/data. Foram extraídos das constantes e chamadas de leitura efetivamente usadas nos scripts, não inferidos pelos nomes dos jobs.

Saída Gold	Entradas reais	Gates prévios
gold/municipio_estacao	silver/ibge/2022; silver/inmet/2023, /2024 e /2025	DQ Silver IBGE e INMET horário
gold/fato_internacao	silver/sih; silver/ibge; silver/cid10; gold/municipio_estacao	DQ SIH, IBGE, CID10 e município-estação
gold/fato_internacao_meteorologia	gold/fato_internacao; silver/inmet_diario	DQ fato internação e DQ INMET diário

Município-estação usa INMET horário, não a agregação diária. Por isso pode iniciar após o DQ horário, sem aguardar o diário. A fato meteorológica também relê sua própria saída para validação pós-gravação; essa leitura não é uma dependência externa nem cria uma aresta circular.

2.1 Entradas dos DQs

- DQ município-estação: lê apenas gold/municipio_estacao.
- DQ fato internação: lê a fato, Silver SIH, Silver IBGE/2022, Silver CID10 e Gold município-estação.
- DQ fato meteorologia: lê a fato meteorológica, a fato base e INMET diário.

Os inputs adicionais dos DQs já estão protegidos pelos ancestrais da transformação imediatamente anterior. O trigger rule all_success foi verificado em todas as seis tasks Gold. Assim, o sucesso de uma única fonte não libera uma transformação que ainda aguarda outras.

2.2 Ambiguidade preservada

A transformação fato_internacao lê silver/ibge recursivamente, enquanto o DQ IBGE e o DQ da fato leem silver/ibge/2022. O caminho não foi alterado para evitar mudança funcional especulativa. Se novas subpastas forem adicionadas sob silver/ibge, a transformação poderá consumir dados além dos cobertos pelo gate de 2022. A equivalência do conteúdo deve ser observada em execução real; não foi feita varredura dos datasets nesta tarefa.

3 Auditoria Spark e transferência de configurações

Origem	Baseline encontrado	Classificação e destino
municipio_estacao.py	master local[2]; UI false	Runtime: master permanece na connection; UI na base comum da DAG

Origem	Baseline encontrado	Classificação e destino
fato_internacao.py	autoBroadcastJoinThreshold -1	Tuning: conf específico da task da fato
fato_internacao_meteorologia.py	shuffle 40; UI false	Tuning/runtime: conf da task meteorológica
Helper DQ herdado da Silver	master local[2]; UI false; shuffle 4	Runtime/tuning: connection, base comum e conf shuffle 4 dos três DQs

Não foram encontrados nos scripts Gold hardcodes de memória, executor cores ou caminhos Python específicos de imagem. appName e nível de log ERROR foram preservados. Opções como mergeSchema e recursiveFileLookup fazem parte da leitura existente e permaneceram intactas.

A propriedade de broadcast foi preservada especificamente na transformação fato internação, pois o comentário anterior registrava sua finalidade de reduzir pressão sobre a memória do driver. O comentário explicativo foi transferido para a DAG. Esse tuning não foi estendido aos DQs, pois eles não o possuíam no baseline.

3.1 Configuração final das seis tasks

Todas usam spark_default e spark.ui.enabled=false. Nenhuma recebe spark.master no conf. Não foram adicionadas configurações de Python, memória ou cores.

Task dentro do grupo gold	Conf adicional	Retries
gold_municipio_estacao	Nenhum	1
dq_gold_municipio_estacao	spark.sql.shuffle.partitions=4	0
gold_fato_internacao	spark.sql.autoBroadcastJoinThreshold=-1	1
dq_gold_fato_internacao	spark.sql.shuffle.partitions=4	0
gold_fato_internacao_meteorologia	spark.sql.shuffle.partitions=40	1
dq_gold_fato_internacao_meteorologia	spark.sql.shuffle.partitions=4	0

As transformações recebem retry_delay de um minuto. As seis tasks mantêm durable=False, conforme o padrão existente. A ausência de shuffle explícito em uma task significa uso da configuração efetiva do ambiente Spark, não ausência de particionamento.

4 Arquivos modificados e criados

Somente cinco arquivos de implementação foram modificados nesta tarefa:

1. dags/tcc_pipeline.py: acrescentados dois dicionários de tuning, seis constantes de caminhos, o TaskGroup gold, seis operadores e suas dependências.
2. src/gold/municipio_estacao.py: removidas duas chamadas do builder, master e UI.
3. src/gold/fato_internacao.py: removida a chamada de configuração de broadcast e seu comentário local; ajuste preservado na DAG.
4. src/gold/fato_internacao_meteorologia.py: removidas as configurações de shuffle e UI do builder.
5. src/quality/gold/common.py: substituída a reexportação do helper Silver por implementação própria de criar_spark.

Não foi necessário criar `spark_session.py` para Gold: o `common.py` existente já é a interface importada pelos três DQs e agora implementa a sessão mínima diretamente. Isso elimina a dependência da Silver sem alterar os imports ou regras dos DQs. **all** e assinatura da função foram preservados.

Não foram criados arquivos de código. Foram criados este relatório Markdown e sua versão PDF. O helper Silver antigo permaneceu intacto, fora do escopo de limpeza desta tarefa; o Gold não o utiliza mais.

5 Grafo final da DAG

Os nomes abaixo representam as tasks dentro de seus respectivos grupos. Uma lista entre colchetes exige sucesso de todos os elementos.

```
inmet:
    silver_inmet -> dq_silver_inmet
    -> silver_inmet_diario -> dq_silver_inmet_diario
ibge:
    silver_ibge -> dq_silver_ibge
cid10:
    silver_cid10 -> dq_silver_cid10
sih:
    silver_sih -> dq_silver_sih

gold:
    [dq_silver_ibge, dq_silver_inmet]
    -> gold_municipio_estacao
    -> dq_gold_municipio_estacao

    [dq_silver_sih, dq_silver_ibge, dq_silver_cid10,
    dq_gold_municipio_estacao]
    -> gold_fato_internacao
    -> dq_gold_fato_internacao

    [dq_gold_fato_internacao, dq_silver_inmet_diario]
    -> gold_fato_internacao_meteorologia
    -> dq_gold_fato_internacao_meteorologia
```

As dependências entre as dez tasks originais foram preservadas. Foram adicionadas somente as arestas para Gold e entre Gold e seus gates. Os ids completos das novas tasks têm prefixo `gold.`, por exemplo `gold.gold_fato_internacao`.

6 Validações executadas

Os checks Python foram executados no worker com `docker compose -f docker-compose.airflow.yaml exec -T airflow-worker python -B -c`. Não iniciaram sessões Spark nem executaram os corpos dos scripts de transformação.

Verificação	Resultado
compile dos arquivos no snapshot, incluindo DAG e helper alterados	PASS
Execução isolada dos imports extraídos por AST dos módulos Gold/DQ	PASS
Comparação textual da Silver e dos três DQs Gold com snapshot	PASS: intactos
Comparação AST dos três scripts Gold, ignorando apenas chamadas config/master anteriores	PASS: restante da estrutura executável idêntico
Busca por .config, .master, /opt/conda e dependência src.quality.silver em Gold/DQ Gold	Nenhuma ocorrência
Importação da DAG via runpy no Airflow	PASS
Número de grupos e tasks	PASS: cinco grupos, 16 tasks
Comparação das dez tasks originais com baseline	PASS: conf, aplicação, retries, delay, connection, nome, trigger rule e arestas internas preservados
Upstreams exatos das seis tasks Gold e reciprocidade dos downstreams	PASS
Ordenação topológica	PASS: 16 tasks, sem ciclos
all_success, retries, connection e existência dos scripts Gold	PASS
Comparação exata dos conf das seis tasks Gold	PASS
Simulação de erro crítico nos três main() DQ Gold	PASS: ValueError propagado e spark.stop chamado
airflow dags list-import-errors	No data found
git diff -check	Sem erros; avisos de normalização LF/CRLF
Revisão integral do diff	Mudanças restritas ao escopo, além do baseline anterior já existente

Os gates foram testados com relatório crítico e sessão simulados, preservando a chamada real a `exigir_aprovacao`. As funções de validação de dados foram substituídas por mocks somente no processo temporário do teste, sem editar seus arquivos. A propagação de erro foi comprovada em Python; o estado FAILED de uma task real não foi observado nesta tarefa.

7 Estatísticas Git e resumo do diff

O comando `git diff -stat` retornou o estado acumulado contra HEAD:

```
dags/tcc_pipeline.py | 155
src/gold/fato_internacao.py | 4
src/gold/fato_internacao_meteorologia.py | 8
src/gold/municipio_estacao.py | 2
src/quality/gold/common.py | 13
src/quality/silver/dq_cid10.py | 2
src/quality/silver/dq_ibge.py | 2
src/quality/silver/dq_inmet.py | 2
src/quality/silver/dq_inmet_diario.py | 2
src/quality/silver/dq_sih.py | 2
```

```

src/silver/cid10.py          | 2
src/silver/ibge.py          | 2
src/silver/inmet.py         | 15
src/silver/inmet_diario.py  | 2
src/silver/sih.py           | 3
15 files changed, 165 insertions(+), 51 deletions(-)

```

Arquivos não rastreados, inclusive relatórios e o helper Silver criado anteriormente, não entram nessa estatística. As linhas Silver exibidas pertencem à refatoração anterior. A comparação com o snapshot inicial desta tarefa confirmou que elas não foram modificadas agora.

O incremento Gold acrescenta configurações e orquestração à DAG, remove 14 linhas dos builders/comentário dos três scripts Gold e transforma common.py em helper independente. Não houve mudança em joins, compatibilidade CID-10, regras meteorológicas, schemas, colunas, filtros, granularidade, valores esperados, paths ou escrita. Nenhum commit ou push foi feito.

8 Limitações, riscos e validação operacional pendente

O pipeline Gold de mais de oito milhões de registros não foi executado. Nenhum dataset foi apagado ou sobrescrito. Também não foram alterados Dockerfiles, requirements, Docker Compose, connection ou permissões.

Os testes de estrutura e AST sustentam a preservação da lógica, mas não substituem execução real para validar recursos, resolução do master, comportamento do spark-submit, duração, consumo de memória e resultados dos DQs. Os valores armazenados na connection não foram reconfigurados nem consultados; a DAG mantém sua referência.

Na próxima execução operacional, devem ser observados os três gates, as contagens esperadas existentes, a aplicação efetiva do broadcast -1 e shuffle 40/4, e a ordem de liberação das tasks. A divergência de escopo do path IBGE deve ser considerada se houver outras subpastas além de 2022.

As Gold usam os modos de escrita existentes, inclusive overwrite. Uma futura execução real poderá substituir suas saídas como já previsto nos scripts; nenhuma escrita ocorreu nesta tarefa. Execuções manuais também passam a depender da submissão externa para receber o tuning e o master que foram retirados dos scripts.

O relatório anterior da Silver é um registro histórico: sua observação de que o DQ Gold ainda dependia do helper Silver descreve o estado anterior. Esta implementação resolve essa dependência.