

Resultados dos experimentos de performance

Análise operacional da DAG `tcc_pipeline` após os Experimentos 1 e 2

11 de setembro de 2026

Sumário

1	Resultado principal	1
2	Fontes e identificação das execuções	2
3	O que foi implementado	2
3.1	Experimento 1 — contagens consolidadas na fato de internação	2
3.2	Experimento 2 — persistência somente do INMET preparado	2
4	Impacto global	3
5	Comparação das 24 tasks	3
6	Experimento 1: resultado do bloco e da task	3
7	Experimento 2: resultado da task meteorológica	4
7.1	Cronômetros observados na execução final	4
7.2	Comparação dos mesmos marcadores de log	4
8	Caminho crítico e contribuição para a redução	5
9	Paralelismo e gargalo atual	6
10	Evidências de preservação funcional	6
11	Ambiente e limites de causalidade	7
12	Recomendação e redação para o TCC	7
13	Horários das 24 tasks da execução final	8
14	Rastreabilidade e entregáveis	9

1 Resultado principal

A última execução da DAG `tcc_pipeline` terminou em **33m25,611s**, com as **24 tasks em sucesso e todas na primeira tentativa**.

Em relação à execução imediatamente anterior, de 46m46,285s, houve redução observada de **13m20,674s, ou 28,53%**. Em relação ao baseline anterior aos experimentos, de 41m46,422s, a redução foi de **8m20,810s, ou 19,98%**.

A Gold fato_internacao_meteorologia caiu de **751,996s para 217,760s**, redução de **71,04%**. Essa task responde contabilmente por **66,72% da redução total** entre as duas últimas runs, pois integra o caminho crítico.

Os logs confirmam **8.409.047 registros antes e depois do join e na gravação**. O DQ final aprovou as verificações de cardinalidade, schema, chaves, flags, correspondência e cobertura.

Os resultados são consistentes com benefício do reaproveitamento do INMET. Entretanto, esta comparação é observacional: a redução de todas as tasks não pode ser atribuída exclusivamente ao Experimento 2.

2 Fontes e identificação das execuções

Foram consultadas as tabelas `dag_run` e `task_instance` do banco PostgreSQL de metadados do Airflow e os logs locais em `logs/dag_id=tcc_pipeline`. Também foram conferidos o código atual dos experimentos, as dependências da DAG e o diff local de configuração.

Esta tarefa apenas analisou os dados já disponíveis e produziu documentação. Não executou jobs, DQs ou a DAG novamente e não alterou código ou datasets.

As três referências principais são:

Referência	Run ID
A — baseline antes dos experimentos	manual__2026-09-10T01:37:19.578492+00:00
B — após Experimento 1	manual__2026-09-10T23:06:31.740806+00:00
C — após Experimentos 1 e 2	manual__2026-09-11T02:23:24.553751+00:00

Referência	Início UTC	Fim UTC	Duração
A	10/09 01:37:20,237862	10/09 02:19:06,659535	41m46,422s
B	10/09 23:06:32,794670	10/09 23:53:19,080142	46m46,285s
C	11/09 02:23:24,765581	11/09 02:56:50,377059	33m25,611s

No horário de São Paulo, a execução C ocorreu em **10/09/2026, das 23:23:24 às 23:56:50**. A data UTC é 11/09.

As três runs possuem a mesma referência de versão da DAG nas task instances: **01a088dc-8205-7d14-bb61-cb94cc782a7b**. Isso identifica a definição da DAG; não comprova, por si só, identidade dos scripts externos ou de toda a infraestrutura entre runs.

3 O que foi implementado

3.1 Experimento 1 — contagens consolidadas na fato de internação

No bloco “Validando campos importantes...” de `src/gold/fato_internacao.py`, 12 actions independentes `filter(...).count()` foram substituídas por uma agregação com 12 expressões e uma action `first()`.

A condição permaneceu NULL ou vazio após trim e cast para string. Foram preservadas as 12 colunas, sua ordem, mensagens e ValueError na primeira coluna inválida. Coalesce preserva zero para DataFrame vazio.

Foi adicionado um cronômetro somente para esse bloco. A implementação anterior foi validada com seis testes sintéticos e preservada no Experimento 2.

3.2 Experimento 2 — persistência somente do INMET preparado

Em `src/gold/fato_internacao_meteorologia.py`, `df_inmet` recebe `persist(StorageLevel.MEMORY_AND_DISK)` após a normalização das chaves e é liberado com `unpersist()` depois da escrita.

A contagem existente de chaves inválidas materializa o cache. Não foi adicionado count de aquecimento. A fato com 8,4 milhões de registros não foi persistida. Join left, broadcast, regras, paths e escrita foram mantidos.

Foram identificadas nove actions consumidoras da linhagem após a preparação: validação de chaves, duplicidades, período, dois anti-joins, estatísticas do join, observações incompletas, amostra e gravação. As contagens iniciais do INMET permanecem antes da persistência.

O Experimento 2 teve três testes sintéticos, incluindo cinco subcasos de erro. Os testes confirmaram igualdade de métricas, linhas, schema e flags, além do uso de InMemoryTableScan. Os seis testes do Experimento 1 e cinco de orquestração também passaram. Esses são resultados da etapa de implementação, não testes repetidos nesta análise.

4 Impacto global

Comparação	Economia observada	Redução
B → C: execução anterior para final	800,674s — 13m20,674s	28,53%
A → C: baseline para final	500,810s — 8m20,810s	19,98%

A execução B havia ficado aproximadamente cinco minutos mais lenta que A, apesar da melhora do bloco do Experimento 1. A execução C ficou abaixo de ambas. Por isso, o relatório mantém os dois referenciais e evita usar somente a execução mais lenta como baseline.

A redução percentual foi calculada por $(\text{tempo anterior} - \text{tempo atual}) / \text{tempo anterior} \times 100$.

5 Comparação das 24 tasks

Todos os valores abaixo estão em segundos. A coluna “Economia B-C” é positiva quando a task ficou mais rápida e negativa quando ficou mais lenta.

Task	A	B	C	Economia B-C
cid10.bronze_cid10	0,480	3,557	0,599	2,958
inmet.bronze_inmet	0,487	3,562	0,613	2,949
sih.bronze_sih	0,661	3,769	0,781	2,988
ibge.bronze_ibge	0,480	3,551	0,590	2,961
cid10.dq_bronze_cid10	0,443	0,584	0,431	0,152
inmet.dq_bronze_inmet	9,317	9,342	9,484	-0,142
ibge.dq_bronze_ibge	0,529	0,644	0,528	0,116
sih.dq_bronze_sih	65,446	68,043	68,016	0,027
ibge.silver_ibge	8,230	9,943	8,966	0,978
cid10.silver_cid10	9,457	11,818	10,613	1,205
inmet.silver_inmet	118,167	147,799	126,026	21,774
ibge.dq_silver_ibge	10,157	12,111	9,721	2,391
cid10.dq_silver_cid10	9,565	11,683	9,398	2,285
sih.silver_sih	1.133,510	1.235,909	1.149,727	86,182
inmet.dq_silver_inmet	56,525	65,659	57,717	7,942
gold.gold_municipio_estacao	26,465	28,886	26,066	2,821
inmet.silver_inmet_diario	514,990	529,913	491,073	38,839
gold.dq_gold_municipio_estacao	8,567	8,646	9,946	-1,300
inmet.dq_silver_inmet_diario	89,201	98,444	81,753	16,691
sih.dq_silver_sih	47,266	73,198	47,494	25,704
gold.gold_fato_internacao	617,946	513,360	396,221	117,139
gold.dq_gold_fato_internacao	19,542	23,785	18,230	5,555
gold.gold_fato_internacao_meteorologia	525,490	751,996	217,760	534,236
gold.dq_gold_fato_internacao_meteorologia	91,577	130,848	103,579	27,269

As durações vêm do campo duration das task instances. Incluem custos do operador e dos processos, não apenas CPU Spark. A soma das economias das 24 tasks não equivale à redução da DAG, devido ao paralelismo.

Na run C, a soma de todas as durações é **2.845,329s**, enquanto o wall-clock é **2.005,611s**. O cálculo do impacto total deve considerar o caminho crítico.

6 Experimento 1: resultado do bloco e da task

Medição	A	B	C
Bloco de campos importantes	273,001s	57,380s	45,625s
Gold fato internação completa	617,946s	513,360s	396,221s

O bloco ficou **83,29% mais rápido que o baseline A**, com economia de **227,376s**. Entre B e C, o bloco melhorou **11,755s**, enquanto a task inteira melhorou **117,139s**.

Como a implementação do Experimento 1 já estava presente em B, a redução adicional da task em C não deve ser tratada como efeito direto da nova persistência na Gold meteorológica: essa outra task executa depois da fato de internação.

Linha observada na run C:

02:47:56.573277 UTC

[PERFORMANCE] Validação consolidada de campos importantes: 45.625 segundos

7 Experimento 2: resultado da task meteorológica

Comparação	Antes	Depois	Economia	Redução
B → C	751,996s	217,760s	534,236s	71,04%
A → C	525,490s	217,760s	307,730s	58,56%

A task passou de **12m31,996s para 3m37,760s** entre as duas últimas runs. A queda também é expressiva quando se usa A, anterior às otimizações, como referência.

7.1 Cronômetros observados na execução final

Log	Tempo
INMET preparação/materialização	43,191s
INMET validações: chave, período e estações	45,639s
Join meteorológico até agregação de validação	1,345s
INMET reutilização total: persistência até escrita	95,664s

Os intervalos se sobrepõem e **não devem ser somados**. Preparação/materialização inclui a primeira action que preenche o cache. Validações inclui esse primeiro cálculo. Reutilização total inclui validações, join, métricas, amostra e escrita.

O tempo de reutilização também não é a duração total da task. Aproximadamente **122,096s** da task estão fora desse intervalo, incluindo inicialização, trabalho anterior à persistência e verificações posteriores à escrita. Não se deve atribuir todo esse restante a uma única operação.

7.2 Comparação dos mesmos marcadores de log

Para evitar comparar cronômetros com abrangências diferentes, os seguintes intervalos foram reconstruídos usando mensagens que existem nas três runs.

Trecho	A (s)	B (s)	C (s)	Redução B-C
Chaves inválidas e duplicidades	79,828	129,011	43,636	66,18%
Chave, período e estações	200,665	316,786	45,636	85,59%
Join até estatísticas	43,996	55,259	1,345	97,57%
Gravação até validação pós-escrita	80,687	105,351	46,076	56,26%

Trecho	A (s)	B (s)	C (s)	Redução B-C
Estatísticas do join até início da escrita	86,988	105,889	2,553	97,59%

Definições dos intervalos:

- **Chaves inválidas e duplicidades:** “Validando chave codigo_estacao + data...” até “Duplicidades na chave INMET”.
- **Chave, período e estações:** a mesma abertura até “Códigos de estação compatíveis”.
- **Join até estatísticas:** “Integrando fato_internacao...” até “Registros antes do JOIN”, emitido após a action agregada.
- **Gravação:** “Gravando Gold...” até “Validando gravação”.
- **Estatísticas até escrita:** de “Registros antes do JOIN” até “Gravando Gold”, incluindo regras, outras métricas e amostra.

A diferença entre os **45,636s derivados dos timestamps** e os **45,639s do perf_counter** é de milissegundos, compatível com pontos de início/fim e transporte de logs distintos.

Os **1,345s do join incluem a agregação de validação**; não representam todas as actions posteriores que voltam a consumir o join, nem somente tempo do algoritmo de join. Da mesma forma, o intervalo de gravação inclui computação da linhagem e escrita, não apenas I/O de disco.

A redução expressiva aparece em várias reutilizações da mesma linhagem, e não somente na primeira contagem. Esse padrão é consistente com o objetivo da persistência. Não substitui medição histórica de leitura física, cache hit, GC ou spill.

8 Caminho crítico e contribuição para a redução

A sequência dominante permanece:

```

sih.bronze_sih
→ sih.dq_bronze_sih
→ sih.silver_sih
→ sih.dq_silver_sih
→ gold.gold_fato_internacao
→ gold.dq_gold_fato_internacao
→ gold.gold_fato_internacao_meteorologia
→ gold.dq_gold_fato_internacao_meteorologia

```

Nas convergências, o DQ Bronze SIH terminou depois do DQ Bronze IBGE; o DQ Silver SIH terminou depois das demais entradas da fato; e o DQ da fato terminou depois do DQ INMET diário. Assim, a cadeia acima determina a conclusão desta run.

Task crítica	Duração C	Economia B-C (s)
sih.bronze_sih	00:00:00,781	2,988
sih.dq_bronze_sih	00:01:08,016	0,027
sih.silver_sih	00:19:09,727	86,182
sih.dq_silver_sih	00:00:47,494	25,704
gold.gold_fato_internacao	00:06:36,221	117,139
gold.dq_gold_fato_internacao	00:00:18,230	5,555
gold.gold_fato_internacao_meteorologia	00:03:37,760	534,236
gold.dq_gold_fato_internacao_meteorologia	00:01:43,579	27,269

Componente	B	C	Economia
Tasks do caminho crítico	2.800,906s	2.001,807s	799,100s
Transições, início e encerramento	5,379s	3,805s	1,574s
Duração da DAG	2.806,285s	2.005,611s	800,674s

A economia da Gold meteorológica, **534,236s**, equivale a **66,72%** da economia total. Os demais **266,438s** vêm da variação nas outras tasks críticas e nas transições.

Essa é uma decomposição contábil do tempo observado. Não significa que 66,72% seja uma estimativa causal isolada do efeito do cache.

9 Paralelismo e gargalo atual

O ramo INMET diário rodou em paralelo ao SIH: sua Silver executou das **02:26:41,254** às **02:34:52,327 UTC**, inteiramente dentro da janela da Silver SIH, das **02:24:34,406** às **02:43:44,133 UTC**.

O DQ INMET diário terminou às **02:36:14,873**, enquanto o DQ da fato só terminou às **02:51:27,341**. O INMET ficou disponível **15m12,468s** antes da outra dependência necessária à integração meteorológica.

A Silver SIH continua sendo a maior task:

- **19m09,727s** nesta execução.
- **57,33% do wall-clock da DAG**.
- Quase o mesmo tempo do baseline A: 18m53,510s.
- Mais rápida que B em 1m26,182s.

Os dois experimentos reduziram o peso das fatos Gold, tornando o SIH proporcionalmente mais dominante. A análise anterior localizou grande parte do tempo SIH na conversão DBF → Parquet; essa decomposição interna não foi medida novamente nesta tarefa.

10 Evidências de preservação funcional

Os mesmos números foram observados nas três execuções comparadas:

Verificação	Resultado
INMET diário	43.840 registros
Estações INMET	40
Fato antes do join	8.409.047
Fato depois do join	8.409.047
Registros gravados	8.409.047
Internações com match	8.236.990
Internações sem match	172.057
Sem match antes do período INMET	172.057
Sem match depois do período INMET	0
Sem match dentro do período INMET	0
Duplicidades de chave INMET	0

As internações anteriores ao período meteorológico foram preservadas. Os logs do DQ final registraram PASS para schema, tipos, cardinalidade, preservação da fato base, nulos/vazios obrigatórios, domínio da flag, unicidade da chave INMET, correspondência das estações, coerência entre flag e motivo, 24 observações nos matches e ausência de métricas sem match.

Coberturas aprovadas no DQ final:

Variável	Cobertura	Referência
Temperatura	95,04%	90%
Umidade	94,66%	90%
Precipitação	84,94%	80%
Vento	86,78%	80%

Essas evidências sustentam preservação dos critérios verificados. Não constituem uma comparação linha a linha de todos os arquivos antes/depois, nem prova de igualdade completa de cada valor do dataset.

11 Ambiente e limites de causalidade

Os comandos spark-submit registrados mantêm **local[2]**. Na fato de internação permanece `autoBroadcastJoinThreshold=1`; na Gold meteorológica permanecem `shuffle.partitions=40` e o broadcast explícito do código. Os logs da Gold meteorológica e do DQ final registram Spark 3.5.0.

O workspace contém uma alteração preexistente no `docker-compose.airflow.yaml`: a publicação da API mudou de **8080:8080 para 8180:8080**. Ela foi apenas observada, não alterada nesta análise. O mapeamento da porta, isoladamente, não demonstra explicação para a redução dos jobs; a inspeção não comprova se houve reinício de serviços ou outras mudanças de ambiente entre runs.

Limitações:

- Há uma execução por estado analisado, sem desenho experimental controlado.
- A e B já apresentavam variação relevante antes da persistência.
- Tasks não alteradas pelo Experimento 2 também ficaram mais rápidas.
- Não há séries históricas de CPU, memória, I/O, GC ou spill nesta análise.
- Cache do sistema operacional, carga concorrente e comportamento de I/O podem variar; não foram identificados como causa comprovada.
- As durações de task incluem inicialização e encerramento; os marcadores de log não são perfis exclusivos de cada estágio.
- A mesma versão de DAG não garante igualdade do conteúdo dos datasets, imagens ou scripts externos em cada instante histórico.

A conclusão defensável é: **a execução após os dois experimentos foi mais rápida, com maior economia concentrada na task alvo do Experimento 2 e manutenção dos controles funcionais observados.**

12 Recomendação e redação para o TCC

Recomenda-se manter as duas alterações localizadas como resultado implementado e registrar estas medições como evidência operacional. Se for necessário sustentar um ganho típico, repetir execuções em condições comparáveis e reportar mediana e dispersão, sem usar apenas o melhor tempo. Nenhuma nova execução foi disparada nesta análise.

Texto sugerido:

Após a consolidação das métricas de validação e a persistência do DataFrame meteorológico preparado, o pipeline apresentou duração de 33min25,611s. Em comparação à execução imediatamente anterior, de 46min46,285s, observou-se redução de 28,53%. A etapa de integração meteorológica apresentou redução de 751,996s para 217,760s, mantendo 8.409.047 registros e aprovação dos controles de qualidade. Como as medições não foram realizadas em um experimento controlado com repetições, os valores representam ganhos observados e não uma estimativa isolada de causalidade.

13 Horários das 24 tasks da execução final

Horários UTC de 11/09/2026, truncados a milissegundos. Todas em success, tentativa 1.

Task	Início	Fim	Duração
cid10.bronze_cid10	02:23:24.963	02:23:25.562	00:00:00,599
inmet.bronze_inmet	02:23:24.963	02:23:25.576	00:00:00,613
sih.bronze_sih	02:23:24.964	02:23:25.745	00:00:00,781
ibge.bronze_ibge	02:23:24.968	02:23:25.558	00:00:00,590
cid10.dq_bronze_cid10	02:23:26.086	02:23:26.517	00:00:00,431
inmet.dq_bronze_inmet	02:23:26.086	02:23:35.570	00:00:09,484
ibge.dq_bronze_ibge	02:23:26.086	02:23:26.614	00:00:00,528
sih.dq_bronze_sih	02:23:26.086	02:24:34.102	00:01:08,016
ibge.silver_ibge	02:23:27.241	02:23:36.207	00:00:08,966
cid10.silver_cid10	02:23:27.241	02:23:37.855	00:00:10,613
inmet.silver_inmet	02:23:36.086	02:25:42.112	00:02:06,026
ibge.dq_silver_ibge	02:23:37.239	02:23:46.960	00:00:09,721
cid10.dq_silver_cid10	02:23:38.378	02:23:47.776	00:00:09,398
sih.silver_sih	02:24:34.406	02:43:44.133	00:19:09,727
inmet.dq_silver_inmet	02:25:43.208	02:26:40.925	00:00:57,717
gold.gold_municipio_estacao	02:26:41.240	02:27:07.305	00:00:26,066
inmet.silver_inmet_diario	02:26:41.254	02:34:52.327	00:08:11,073
gold.dq_gold_municipio_estacao	02:27:08.190	02:27:18.136	00:00:09,946
inmet.dq_silver_inmet_diario	02:34:53.120	02:36:14.873	00:01:21,753
sih.dq_silver_sih	02:43:44.336	02:44:31.830	00:00:47,494
gold.gold_fato_internacao	02:44:32.571	02:51:08.792	00:06:36,221
gold.dq_gold_fato_internacao	02:51:09.111	02:51:27.341	00:00:18,230
gold.gold_fato_internacao_meteorologia	02:51:27.733	02:55:05.493	00:03:37,760
gold.dq_gold_fato_internacao_meteorologia	02:55:06.370	02:56:49.949	00:01:43,579

14 Rastreabilidade e entregáveis

Fontes consultadas:

- PostgreSQL/Airflow: dag_run e task_instance, com filtro dag_id=tcc_pipeline e as três run_ids identificadas.
- Logs de gold.gold_fato_internacao, gold.gold_fato_internacao_meteorologia e respectivos DQs; comandos spark-submit e timestamps das tasks.
- Código atual das duas Gold, dependências da DAG e diff do Compose.
- Relatórios anteriores: Relatorio_Performance_Operacional_Airflow e Relatorio_Experimento_2_Persistencia_INME

Valores calculados:

- Wall-clock = end_date – start_date da run.
- Redução = duração anterior – duração final.
- Percentual = redução / duração anterior $\times$ 100.
- Caminho crítico = sequência de dependências cujos predecessores terminaram por último nas convergências.
- Intervalos internos = diferenças entre os mesmos marcadores de log.
- Participação da Gold meteorológica = sua economia / economia do wall-clock.

Os logs estão sob logs/dag_id=tcc_pipeline, em diretórios run_id correspondentes. No Windows, os dois-pontos podem aparecer com representação especial nos nomes desses diretórios.

Arquivos produzidos nesta análise: **docs/Relatorio_Resultados_Performance_Experimentos_1_2.md** e sua versão **PDF**. Os relatórios anteriores foram preservados.